

Simulação de Fila M/M/1 com Prioridade Dinâmica por Idade: Análise de Desempenho e Justiça em Redes de Comunicação

Henrique Pereira

Instituto Nacional de Telecomunicações (Inatel)
Santa Rita do Sapucaí, Brasil
henrique.chagas@mtel.inatel.br

Pedro Guilherme

Instituto Nacional de Telecomunicações (Inatel)
Santa Rita do Sapucaí, Brasil
pedro.fernandes@mtel.inatel.br

Abstract—Este artigo apresenta o desenvolvimento e a análise de desempenho de um modelo de fila $M/M/1$ com política de prioridade dinâmica baseada no tempo de espera (idade) do cliente. O sistema avalia duas classes de usuários: a Classe A (baixa prioridade) e a Classe B (alta prioridade), cujas chegadas seguem processos de Poisson independentes. O diferencial do modelo proposto consiste no mecanismo de promoção automática: se um cliente da Classe A exceder um limiar de tempo T na fila de espera, sua prioridade é elevada ao nível da Classe B para evitar cenários de privação de serviço (*starvation*). Por meio de uma simulação de eventos discretos, o sistema foi validado analiticamente e comparado com disciplinas clássicas (FIFO e prioridade estrita), diferentes distribuições de tempo de serviço (Exponencial, Determinística e Erlang-2) e limitações de armazenamento (buffers finitos). Os resultados demonstram que a prioridade dinâmica estabelece um compromisso regulável e eficiente entre a garantia de qualidade de serviço (QoS) para o tráfego prioritário e a justiça de atendimento para o tráfego convencional.

Index Terms—Teoria de Filas, Prioridade Dinâmica, Envelhecimento de Processos, Simulação de Eventos Discretos, Qualidade de Serviço (QoS).

I. INTRODUÇÃO

Na arquitetura moderna de redes de computadores e sistemas de telecomunicações, a differentiation de serviços é um requisito fundamental para garantir a Qualidade de Serviço (QoS). Pacotes de voz e vídeo em tempo real, por exemplo, demandam baixos índices de latência e flutuação de atraso (*jitter*), justificando a atribuição de alta prioridade em relação ao tráfego de dados convencionais (como e-mails ou downloads de arquivos).

No entanto, a aplicação de políticas de prioridade estrita introduz um problema clássico na teoria de filas: a injustiça severa com as classes de menor prioridade. Sob condições de carga elevada de tráfego prioritário, a classe de baixa prioridade pode sofrer de *quase-starvation*, experimentando atrasos excessivos ou até mesmo a interrupção completa do escoamento de pacotes.

Para mitigar esse comportamento sem remover por completo os benefícios do tráfego em tempo real, mecanismos de envelhecimento (*aging*) despontam como uma solução intermediária promissora. Este trabalho investiga uma fila $M/M/1$ dotada

de prioridade dinâmica por idade. O objetivo central é analisar como a introdução de um limiar de tempo T equilibra a balança entre eficiência e justiça, avaliando o comportamento do sistema sob diferentes distribuições de serviço e restrições de memória física (capacidade de buffer).

II. MODELAGEM DO SISTEMA

O sistema sob análise simula um nó de processamento (servidor único) operando sob regime não preemptivo, o que significa que, uma vez iniciado o atendimento de um cliente, este não será interrompido por novas chegadas de prioridade superior.

O fluxo de entrada é composto por duas entidades distintas:

- **Classe A (Normal):** Clientes inseridos inicialmente na fila de baixa prioridade.
- **Classe B (Prioritária):** Clientes inseridos diretamente na fila de alta prioridade.

As chegadas de ambas as classes seguem processos de Poisson independentes com taxas λ_A e λ_B , respectivamente. O servidor atende a apenas um cliente por vez de forma contínua. A fila adota a política FIFO (*First-In, First-Out*) interna para o desempate dentro de cada nível de prioridade.

O mecanismo dinâmico funciona por meio de um temporizador associado a cada cliente da Classe A que monitora seu tempo de permanência na fila. No instante em que o tempo de espera ultrapassa o limiar T configurado, o cliente é movido para a cauda da fila de alta prioridade. As variáveis de estado do sistema englobam o estado de ocupação do servidor (livre ou ocupado), a quantidade de elementos instantâneos na fila de alta prioridade, o tamanho instantâneo da fila de baixa prioridade, o número médio de clientes na fila e no sistema, bem como a utilização do servidor.

III. METODOLOGIA DE SIMULAÇÃO

A metodologia adotada baseia-se no paradigma de Simulação de Eventos Discretos (SED), implementada por meio de rotinas estruturadas em linguagem Python. O simulador gerencia de forma cronológica uma lista de eventos futuros (FEL – *Future Event List*).

Os eventos modelados e seus respectivos blocos lógicos estruturados são definidos por:

- **Chegada da Classe A:** Conforme mapeado no diagrama estrutural da Fig. 1, este evento agenda a próxima chegada da mesma classe e coloca o cliente na respectiva fila. Simultaneamente, gera-se um agendamento preventivo determinístico na FEL para o instante $\text{Tempo_Atual} + T$, que disparará a promoção caso o cliente ainda permaneça aguardando.
- **Chegada da Classe B:** Agenda a próxima chegada da classe correspondente e direciona o cliente diretamente à fila prioritária.
- **Promoção por Envelhecimento da Classe A:** Disparado caso o cliente associado ainda permaneça na fila de baixa prioridade no instante programado, movendo-o imediatamente para o nível superior.
- **Partida do Servidor:** Conforme mapeado no fluxo operacional da Fig. 2, finaliza o atendimento atual, computa métricas e realiza uma varredura condicional nas filas. O servidor prioriza estritamente a fila de alta prioridade antes de verificar o nível convencional para iniciar o próximo serviço.




Fig. 1. Fluxograma lógico descritivo para o evento de chegada com o agendamento preventivo do envelhecimento da Classe A.

A estabilidade e o comportamento do sistema foram testados a partir de um cenário-base controlado com os seguintes parâmetros fixos: taxa de chegada da Classe A ($\lambda_A = 0.50$), taxa de chegada da Classe B ($\lambda_B = 0.25$), taxa de serviço do servidor ($\mu = 1.00$). A intensidade de tráfego total ρ é dada por:

$$\rho = \frac{\lambda_A + \lambda_B}{\mu} = 0.75 \quad (1)$$




Fig. 2. Fluxograma analítico para o evento de partida do servidor com regras de tratamento de prioridade consecutiva.

O limiar de envelhecimento base adotado foi de $T = 2.00$ unidades de tempo. O método das Replicações Independentes foi empregado para garantir a precisão estatística. Foram realizadas 7 replicações independentes para cada cenário, onde cada replicação executou até atingir a marca de 25.000 partidas completas do servidor.

IV. RESULTADOS E DISCUSSÃO

A. Validação Analítica do Simulador

Antes de realizar os experimentos dinâmicos, o simulador foi submetido a cenários de controle cujas soluções analíticas são descritas pela literatura matemática tradicional. Foram avaliados os modelos $M/M/1$ FIFO Puro e $M/M/1$ com Prioridade Estrita Não Preemptiva. A Tabela I expõe os resultados teóricos face aos dados numéricos simulados.

TABLE I
VALIDAÇÃO ANALÍTICA DO SIMULADOR

Cenário de Controle e Disciplina	Teórico (W_q)	Simulado (W_q)
$M/M/1$ FIFO - Classe A	3.0000	3.0560
$M/M/1$ FIFO - Classe B	3.0000	3.0509
Prioridade Estrita - Classe A	4.0000	4.0821
Prioridade Estrita - Classe B	1.0000	1.0099

A proximidade verificada entre as estimativas teóricas e as saídas coletadas via simulação comprova a corretude e a consistência lógica do motor do simulador desenvolvido para modelar os regimes de atendimento estáveis.

B. Comparação entre Disciplinas de Fila

Fixando o limiar de promoção em $T = 2.00$, comparou-se a política dinâmica contra os regimes tradicionais. A Tabela II consolida os tempos médios de espera em fila obtidos com seus respectivos intervalos de confiança.

Os dados revelam que a inclusão da prioridade dinâmica reduziu a espera da Classe A em 14,78% (de 4,0821 para 3,4790) em relação à prioridade estrita, mitigando o efeito de penalização excessiva. Aproximadamente 48,65% de todos os clientes da Classe A usufruíram do benefício da promoção automática por idade.

TABLE II
IMPACTO DA DISCIPLINA NO TEMPO DE ESPERA EM FILA

Disciplina de Atendimento	Espera Classe A (W_{qA})	Espera Classe B (W_{qB})	Espera Total	Fração de A Promovida
FIFO	3,0560 $\pm$ 0,1235	3,0509 $\pm$ 0,1192	3,0543	0,00%
Prioridade Estrita	4,0821 $\pm$ 0,1778	1,0099 $\pm$ 0,0196	3,0543	0,00%
Prioridade Dinâmica	3,4790 $\pm$ 0,1335	2,2096 $\pm$ 0,1066	3,0543	48,65%

Em contrapartida, o tempo de espera da Classe B cresceu 118,79% (de 1.0099 para 2.2096), refletindo o custo do mecanismo de justiça incorporado. Frente ao FIFO convencional, contudo, a prioridade dinâmica reduziu o atraso sofrido pela Classe B em 27,58% (de 3.0509 para 2.2096), provando que o benefício à classe prioritária não foi anulado. Note que a utilização do servidor manteve-se constante em 0,7490 para todas as disciplinas.




Fig. 3. Comparação do tempo médio de espera em fila entre as disciplinas FIFO, Prioridade Estrita e Prioridade Dinâmica.

C. Análise de Sensibilidade ao Limiar T

A flexibilidade do modelo proposto foi testada alterando a janela de envelhecimento T sob a política dinâmica. Os resultados estão sumarizados na Tabela III.

TABLE III
SENSIBILIDADE DO SISTEMA EM FUNÇÃO DE T

Limiar de Envelhecimento (T)	Espera Classe A (W_{qA})	Espera Classe B (W_{qB})	Porcentagem de Promoções de A
$T = 1$	3,3727 $\pm$ 0,1313	2,4210 $\pm$ 0,1080	59,60%
$T = 2$	3,4790 $\pm$ 0,1335	2,2096 $\pm$ 0,1066	48,65%
$T = 4$	3,6411 $\pm$ 0,1375	1,8871 $\pm$ 0,0998	33,70%

Valores reduzidos de T ($T = 1$) provocam a ascensão precoce da Classe A (com taxa de promoção de 59,60%), aproximando o sistema ao comportamento equilibrado de um canal FIFO. Já valores elevados de T ($T = 4$) restringem o benefício da promoção a apenas 33,70% dos clientes da Classe A. À medida que $T \rightarrow \infty$, a dinâmica converge para o regime de prioridade estrita.

D. Comparação entre Distribuições de Tempo de Serviço

Afastando-se da premissa markoviana, avaliou-se a robustez da disciplina dinâmica substituindo o tempo de atendimento




Fig. 4. Impacto da variação do limiar de tempo T nos tempos de espera e na taxa de promoção automática da Classe A.

exponencial por distribuições de menor variabilidade: Determinística ($M/D/1$) e Erlang-2 ($M/E_2/1$). Ambas foram parametrizadas para manter a mesma taxa média de serviço $\mu = 1.00$.

TABLE IV
IMPACTO DA VARIABILIDADE DO SERVIÇO NA FILA DINÂMICA

Distribuição do Serviço	Espera Classe A (W_{qA})	Espera Classe B (W_{qB})	Espera Total (W_q)	Fração de A Promovida
Exponencial	3,4790 $\pm$ 0,1335	2,2096 $\pm$ 0,1066	3,0543	48,65%
Erlang-2	2,6652 $\pm$ 0,0543	1,5473 $\pm$ 0,0382	2,2912	44,24%
Determinística	1,7900 $\pm$ 0,0250	0,8686 $\pm$ 0,0291	1,4818	34,53%

Como observado na Tabela IV, reduzir o coeficiente de variação do tempo de atendimento impacta positivamente o desempenho global. O serviço determinístico (variância zero) cortou o atraso médio total de 3,0543 para 1,4818, reduzindo de forma drástica as esperas individuais e diminuindo a necessidade de promoção automática da Classe A para 34,53%, dado que a alta variabilidade do modelo exponencial atua como o principal fator gerador de gargalos randômicos.




Fig. 5. Efeito das distribuições Exponencial, Erlang-2 e Determinística no comportamento estatístico e percentis de cauda da espera.

E. Avaliação da Capacidade de Armazenamento (Buffer)

Por fim, removeu-se a hipótese de capacidade infinita para analisar o impacto do descarte de pacotes devido ao transbordo de buffer (*tail drop*), fixando a política dinâmica ($T = 2$) e os parâmetros de tráfego base.

TABLE V
IMPACTO DE RESTRIÇÕES DE BUFFER FINITO

Capacidade do Buffer	Espera Classe A (W_{qA})	Espera Classe B (W_{qB})	Espera Total	Taxa de Perda
Infinito	$3,4790 \pm 0,1335$	$2,2096 \pm 0,1066$	3,0543	0,00%
20 Posições	$3,4382 \pm 0,1511$	$2,1429 \pm 0,1146$	3,0048	0,12%
10 Posições	$2,7891 \pm 0,0752$	$1,6481 \pm 0,0608$	2,4074	1,46%

- [2] R. Jain, *The Art of Computer Systems Performance Analysis: Techniques for Experimental Design, Measurement, Simulation, and Modeling*. John Wiley & Sons, 1991.
- [3] S. B. Mafra, *Slides e Notas de Aula da Disciplina TP 547 - Princípios de Simulação de Sistemas de Comunicação*. Inatel, 2026.

Os dados da Tabela V indicam que buffers compactos limitam fisicamente o tamanho máximo das filas, provocando uma redução no tempo médio de espera dos clientes que conseguem admissão (queda na espera total para 2,4074 no tamanho 10). Contudo, essa aparente melhoria introduz uma taxa de descarte de 1,46% e derruba a utilização útil do servidor para 0,7380. Tal configuração torna-se viável somente em redes tolerantes a perdas de pacotes mas altamente sensíveis a atrasos de transmissão.




Fig. 6. Curvas de desempenho e taxa de descarte (*loss rate*) em função do tamanho restrito do buffer do sistema.

V. CONCLUSÃO

Os experimentos realizados por meio do simulador validado permitiram caracterizar o comportamento de filas com prioridade dinâmica por idade. A fila $M/M/1$ com prioridade dinâmica por idade funciona como um mecanismo intermediário entre o FIFO puro e a prioridade estrita: ela preserva parte do benefício da classe prioritária, mas reduz a penalização excessiva imposta à classe normal por meio de promoção automática após um tempo de espera controlado por T .

O administrador do sistema ganha o controle de um *trade-off* preciso: ajustando o valor de T , pode-se caminhar de forma suave entre o equilíbrio absoluto (FIFO) ou a segregação de desempenho (prioridade estrita). Adicionalmente, verificou-se que a estabilização de atrasos extremos depende fortemente da contenção da variabilidade do tempo de serviço e de um dimensionamento cirúrgico da capacidade do buffer físico para acomodar oscilações sem penalizar o sistema com descartes em excesso.

REFERENCES

- [1] L. Kleinrock, *Queueing Systems, Volume II: Computer Applications*. New York: John Wiley & Sons, 1976.